Q-learning - umelá inteligencia na obzore?

Ing. Michal CHOVANEC
Fakulta riadenia a informatiky

Apríl 2016

Obsah

- Reinforcement learing
- Q-learning algoritmus
- Možnosti aproximácie

Reinforcement learing

- Zistenie stavu
- Výber akcie
- Vykonanie akcie
- Prechod do ďalšieho stavu
- Získanie odmeny alebo trestu
- Učenie sa zo získanej skúsenosti

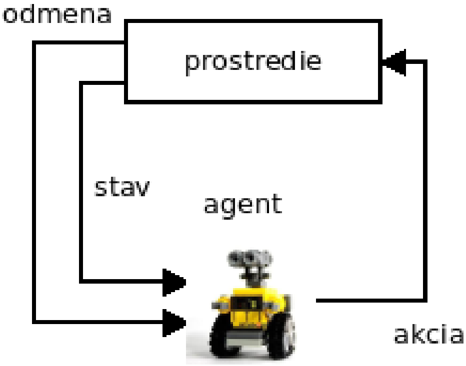

Výhody

Definuje sa čo robiť, nie ako to robiť

- vďaka odmeňovacej funkcií
- agent sa môže naučiť všetky detaily problému

Lepšie konečné riešenie

- založené na skutočnej skúsenosti, nie skúsenosti programátora
- treba menej ľudského času na nájdenie dobrého riešenia

Voľba stratégie, 2 stavy

Odmeny sú známe v každom prechode

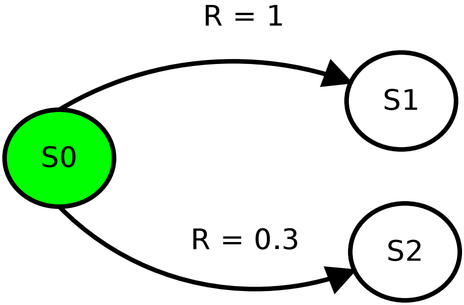

Ohodnotenie ciest :

- $Q(S0, S1) = 1$
- $Q(S0, S1) = 0.3$

Najlepšia cesta : $S0, S1$

Voľba stratégie, viac stavov

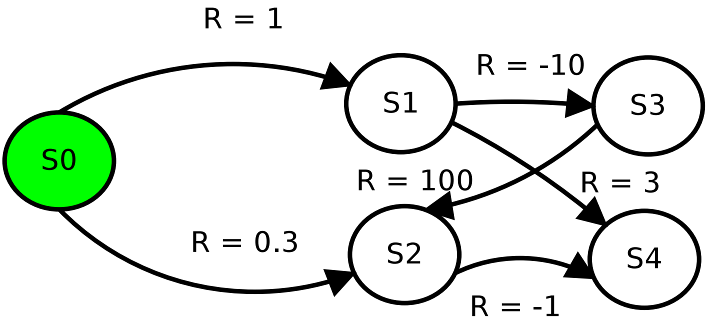

Ohodnotenie ciest :

- $Q(S0, S1, S3) = 1 + (-10) = -9$
- $Q(S0, S1, S4) = 1 + 3 = 4$
- $Q(S0, S2, S4) = 0.3 + () - 1) = -0.7$
- $Q(S0, S1, S3, S2, S4) = 1 + (-10) + 100 + (-1) = 90$
- ...

Voľba stratégie, viac stavov

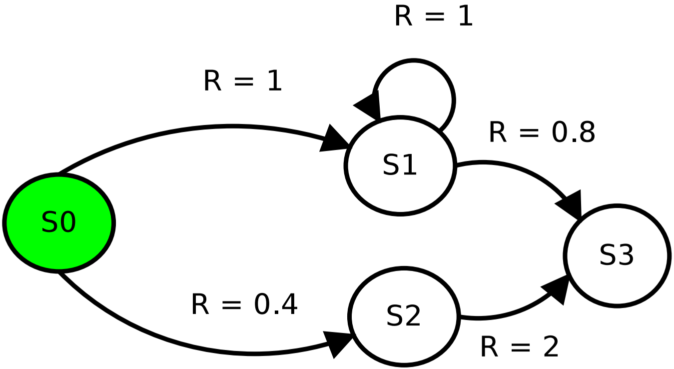

Ohodnotenie ciest :

- $Q(S0, S2, S3) = 0.4 + 2 = 2.4$
- $Q(S0, S1, S3) = 1 + 1 = 2$
- $Q(S0, S1, S1, S1) = 1 + 1 + 1 = 3$
- $Q(S0, S1, S1, S1, S1) = 1 + 1 + 1 + 1 = 4$
- $Q(S0, S1, S1, S1, S1, S1, ...) = 1 + 1 + 1 + 1 + 1 + ... + 1 = \infty$

Zabúdanie $Q' = R + 0.9Q$

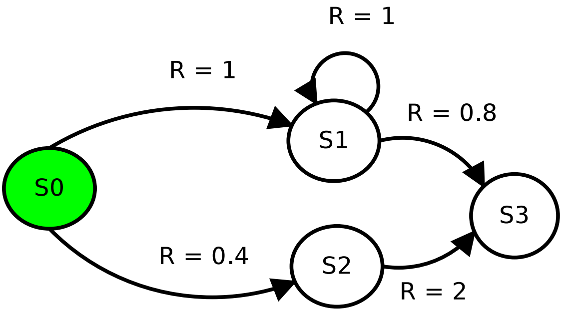

Ohodnotenie ciest :

- $Q(S0, S2, S3) = 2 + 0.9 * 0.4 = 2.36$
- $Q(S0, S1, S3) = 1 + 0.9 * 1 = 1.9$
- $Q(S0, S1, S1, S1) = 1 + 0.9 * (1 + 0.9 * 1) = 2.71$
- $Q(S0, S1, S1, S1, S1) = 1+0.9*(1+0.9*(1+0.9*1)) = 3.439$
- $Q(S0, S1, S1, S1, S1, S1, ...) = 10 <\!\!-\!\!-$
- $Q(S0, S1, S1, S1, S1, S1, ..., S3) = 11 <\!\!-\!\!-$

Reinforcement learing

Čo potrebuje agent?

- Určiť stav
- Vybrať známu akciu
- Dostať odmenu (aj nulovú)
- Pamätať si

Čo nepotrebuje agent?

- Dané správanie
- Vedieť kam sa vykonaním akcie dostane
- Mať model prostredia
- Nenulovú odmenu v každom prechode

Reinforcement learing

Čo ak odmeny NIE sú známe v každom prechode ?

- šachy, go, pacman
- chôdza, pohyb mechanického ramena

Ilustračný príklad - inicializácia

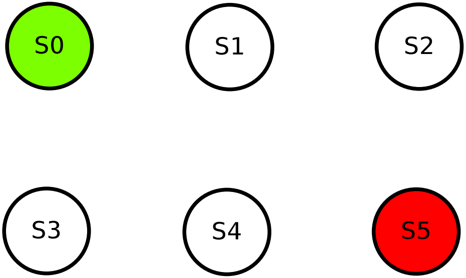

Ilustračný príklad - prechod do ďalšieho stavu

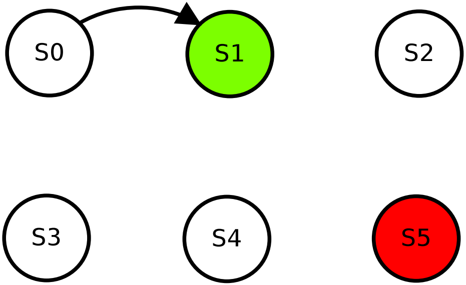

Ilustračný príklad - prechod do ďalšieho stavu

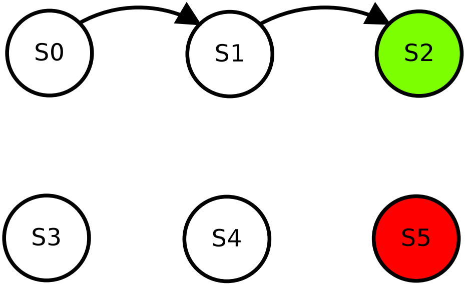

Ilustračný príklad - prechod do cieľového stavu

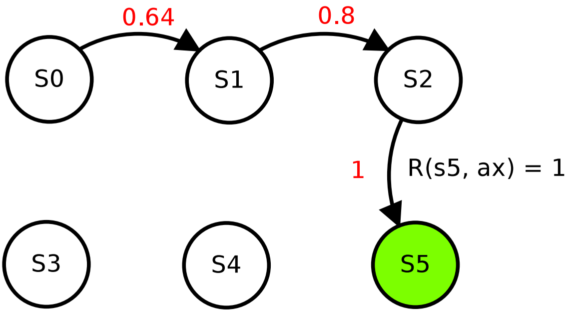

Ilustračný príklad - ďalšie prechody

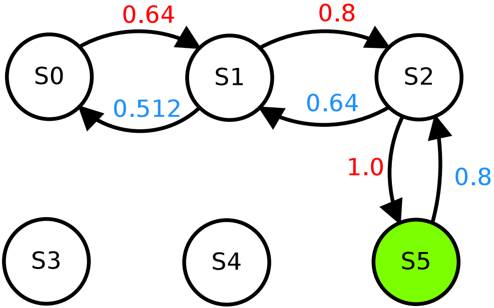

Ilustračný príklad - konečný stav algoritmu :)

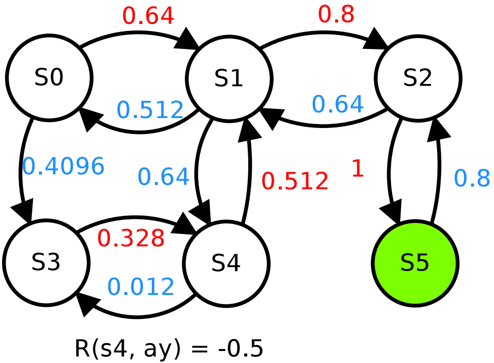

Q-learning algoritmus

Daná je funkcia ohodnotení

$$Q(s(n), a(n)) = R(s(n), a(n)) + \gamma \max_{a(n-1) \in \mathbb{A}} Q(s(n-1), a(n-1))$$

kde

- $R(s(n), a(n))$ je odmeňovacia funkcia s hodnotami v $\langle -1, 1 \rangle$,
- $Q(s(n-1), a(n-1))$ je odmeňovacia funkcia v stave $s(n-1)$ pre akciu $a(n-1)$,
- γ je odmeňovacia konštanta a platí $\gamma \in (0, 1)$.

Odmeňovacia funkcia

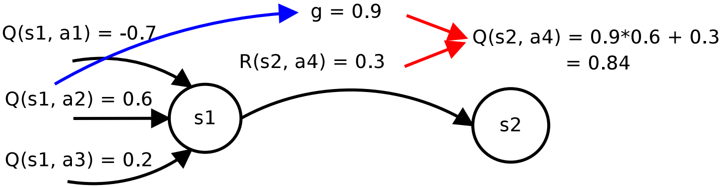

Implementačné problémy

Problémy tabuľkovej interpretácie $Q(s(n), a(n))$:

- pre veľké n_s alebo n_a narastajú pamäťové nároky,
- o nevyplnených $Q(s(n), a(n))$ nevieme povedať nič,
- pre rozsiahle stavové priestory ťažko vypočítateľné,
- ako aproximovať $Q(s(n), a(n))$?

Aproximácia neurónovou sieťou

Utopická predstava :

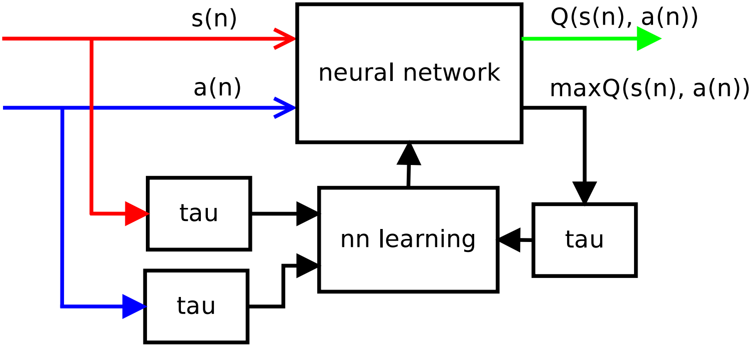

Prečo nedáva správne výsledky?

Hypotéza

Na základe experimetov - Snowball problém

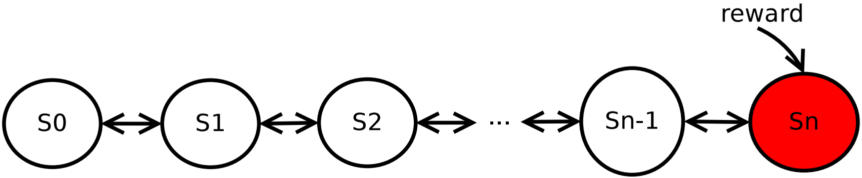

Pre korektné vyplnenie hodnôt v s_{n-1} sa vyžaduje korektá hodnota v s_n

$$Q(s(1), a(1)) = R(s(1), a(1)) + \gamma \max_{a(0) \in \mathbb{A}} Q(s(0), a(0))$$

$$Q(s(2), a(2)) = R(s(2), a(2)) + \gamma \max_{a(1) \in \mathbb{A}} Q(s(1), a(1))$$

$$\ldots$$

Učenie doprednej siete

- Nie je homogénne!
- V priebehu učenia $Q(s(n), a(n))$ chaoticky osciluje okolo požadovanej hodnoty.
- Ani po 10-mil. iteráciach sa hodnota neustáli na požadovanej hodnote.

Je možné zostaviť neurónovú sieť, ktorá sa dá naučiť lokálne?

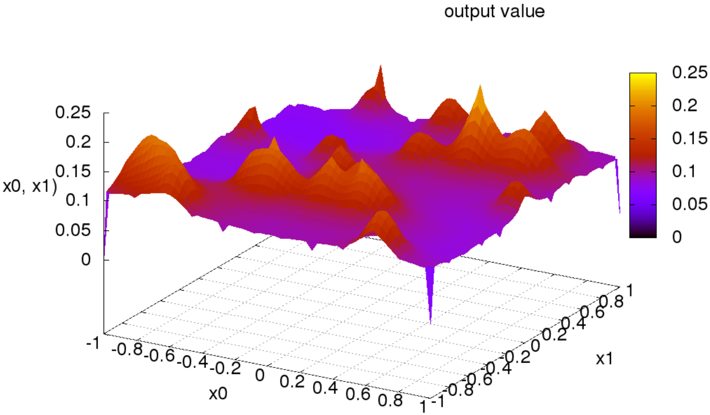

Q-learning algoritmus - aproximácia

Bázické funkcie

$$f_j^1(s,a) = e^{-\beta_{aj} \sum\limits_{i=1}^{n_s} (s_i - \alpha_{aji})^2}$$

$$f_j^2(s,a) = \frac{1}{1 + \beta_{aj} \sum\limits_{i=1}^{n_s} (s_i - \alpha_{aji})^2}$$

a ich lineárna kombinácia

$$Q^x(s,a) = \sum_{j=1}^{l} w_{ja} f_j^x(s,a)$$

kde l je počet bázických funkcií a x je voľba typu bázickej funkcie.

Q-learning algoritmus - aproximácia

Tabuľka pre vybrané hodnoty - umožní zachytit skokovú zmenu
Gaussova krivka - dokáže pokryť nenulovými hodnotami celý definyčný obor

$$P_i(s(n), a(n)) = \begin{cases} r_{ai} & if \ \ s(n) = \alpha_i^1 \\ 0 & inak \end{cases} \tag{1}$$

$$H_j(s(n), a(n)) = w_{aj} e^{-\beta_{aj} \sum_{i=1}^{n_s} (s_i(n) - \alpha_{aji}^2)^2} \tag{2}$$

$$Q(s(n), a(n)) = \sum_{i=1}^{I} P_i(s(n), a(n)) + \sum_{j=1}^{J} H_j(s(n), a(n)) \tag{3}$$

Q-learning algoritmus - aproximácia

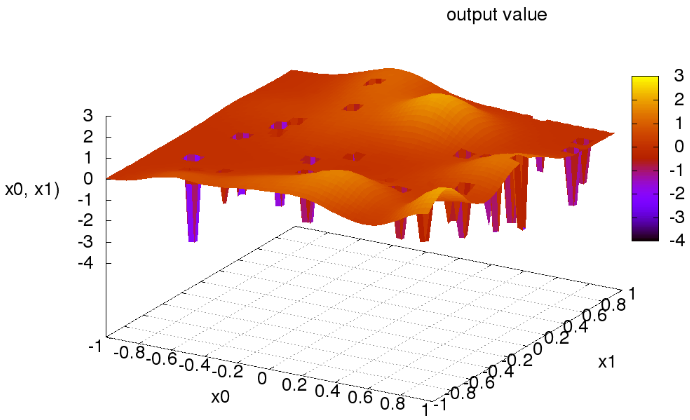

Obr. : Znázornenie predmetnej funkcie

Bloková schéma syntézy testovaného riešenia

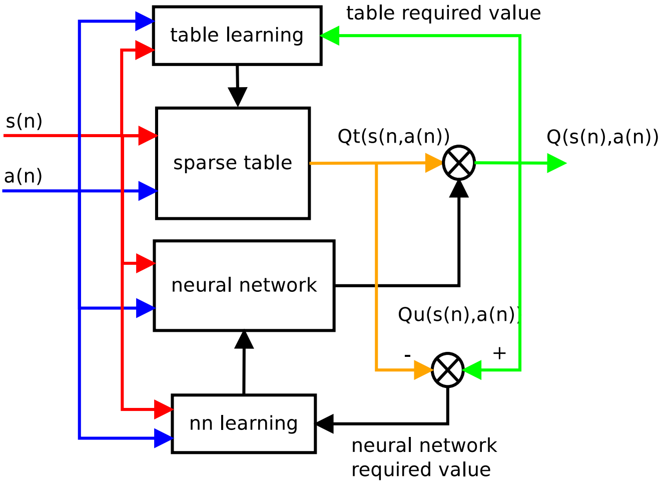

Schéma priebehu experimentov

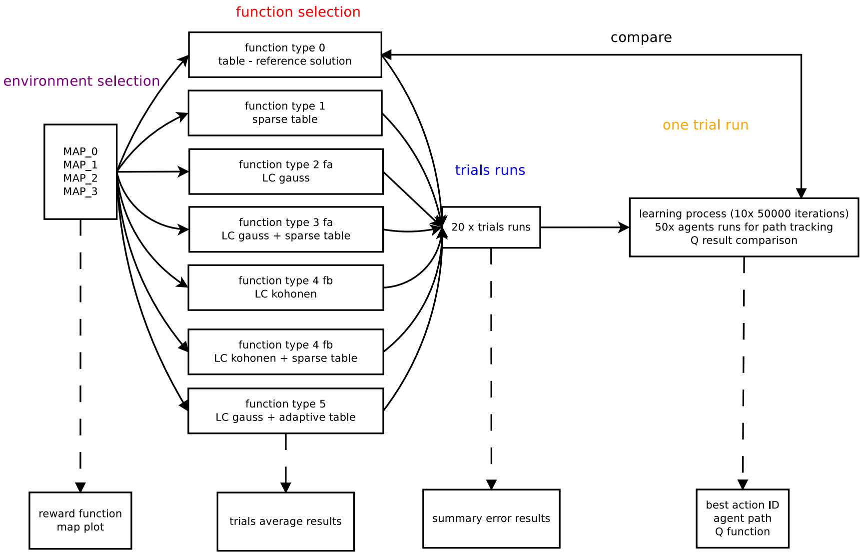

Návrh experimentov - podmienky

- 50000 iterácií učenia
- rozmer s je $n_s = 2$, rozmer a je $n_a = 2$
- predpis funkcie ohodnotení

$$Q(s(n), a(n)) =$$
$$\alpha Q(s(n-1), a(n-1))$$
$$(1-\alpha)(R(s(n), a(n)) + \gamma \max_{a(n-1) \in \mathbb{A}} Q(s(n-1), a(n-1))$$

- $R(s(n), a(n)) \in \langle -1, 1 \rangle$ náhodná mapa s 1 cieľovým stavom
- $\gamma = 0.98$ a $\alpha = 0.7$
- hustota referenčného riešenia = 1/32 (4096 stavov)
- počet akcií v každom stave = 8
- hustota riedkej tabuľky = 1/8 (1:16 pomer)
- počet bázických funkcií $I = 64$
- rozsah parametrov
  - $\alpha_{ja}(n) \in \langle -1, 1 \rangle$
  - $\beta_{ja}(n) \in \langle 0, 200 \rangle$
  - $w_{ja}(n) \in \langle -4, 4 \rangle$

Funkcia R(s, a), mapa 1 - Výsledky experimentov

pre každý stav je zvolená rovnaka množina akcií.
Ďalej platí $s = (s[0], s[1])$.

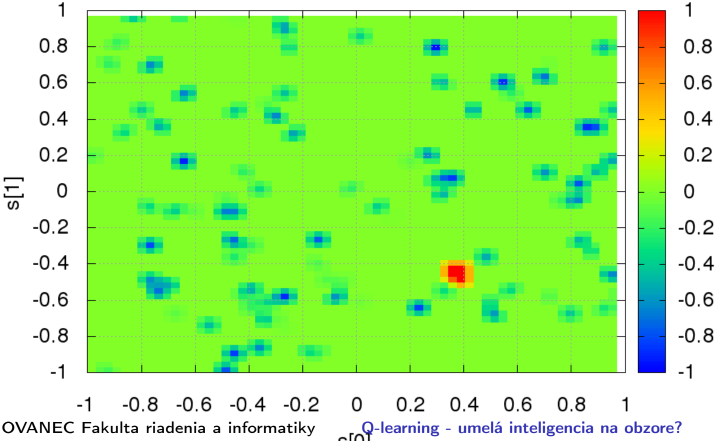

Porovnanie s ostatnými

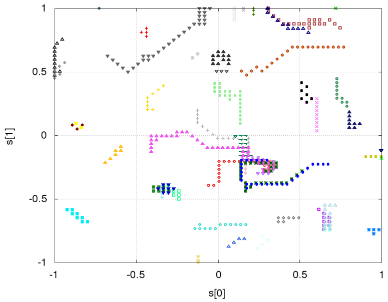

Obr. : Dráha robotov, funkcia 2 - Gauss

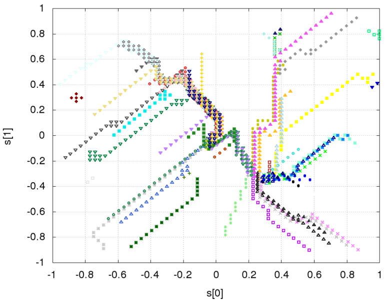

Obr. : Dráha robotov, funkcia 6 - Peak and Hill

Chybové funkcie - Výsledky experimentov

$$e_{jt}(s) = (Q_{rt}(s, a - Q_{jt}(s, a))^2$$

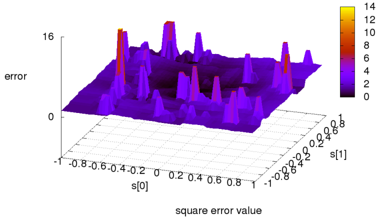

Obr. : sparse table

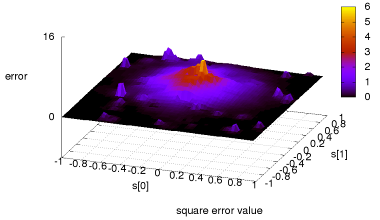

Obr. : linear combination Gauss

Chybové funkcie - Výsledky experimentov

$$e_{jt}(s) = (Q_{rt}(s, a - Q_{jt}(s, a))^2$$

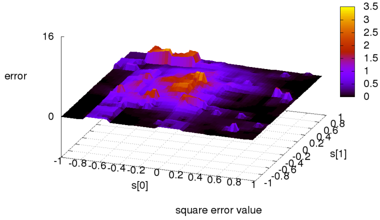

Obr. : sparse table + linear combination Gauss

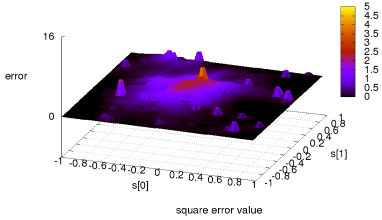

Obr. : linear combination Kohonen function

max Q(s, a) - Výsledky experimentov

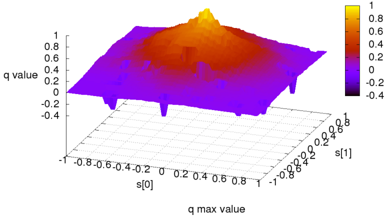

Obr. : reference table

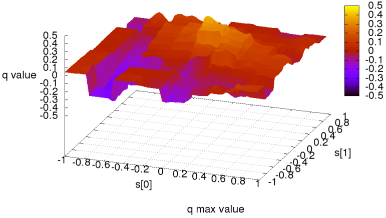

Obr. : sparse table + linear combination Gauss

Mapa 0 - Výsledky experimentov

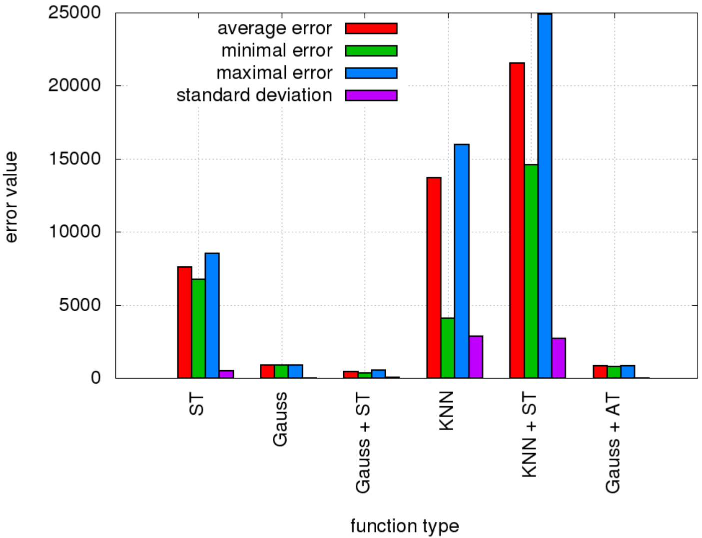

Porovnanie s ostatnými

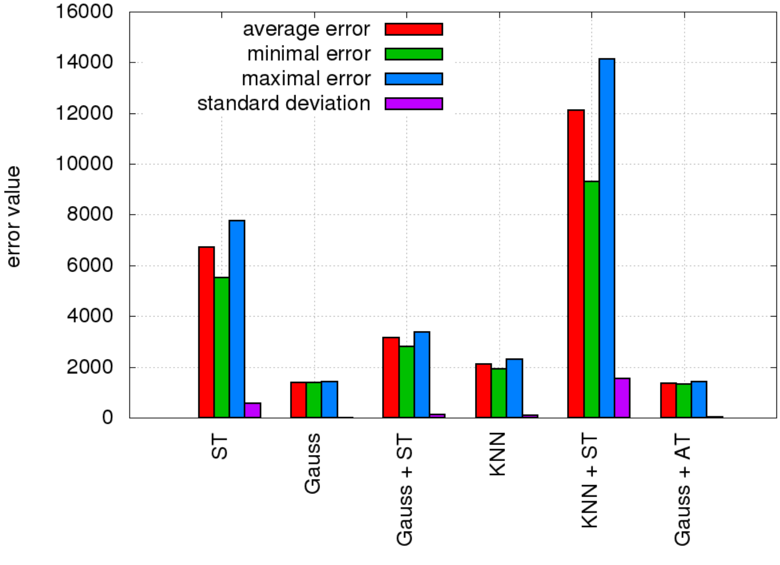

Mapa 1 - Výsledky experimentov

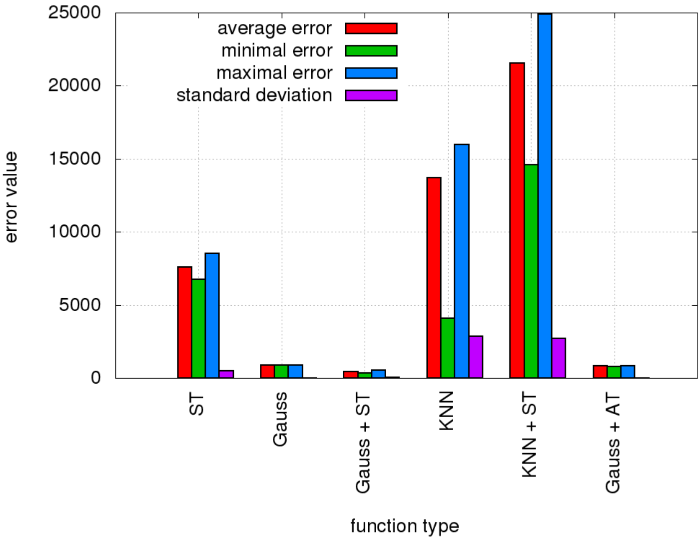

Mapa 2 - Výsledky experimentov

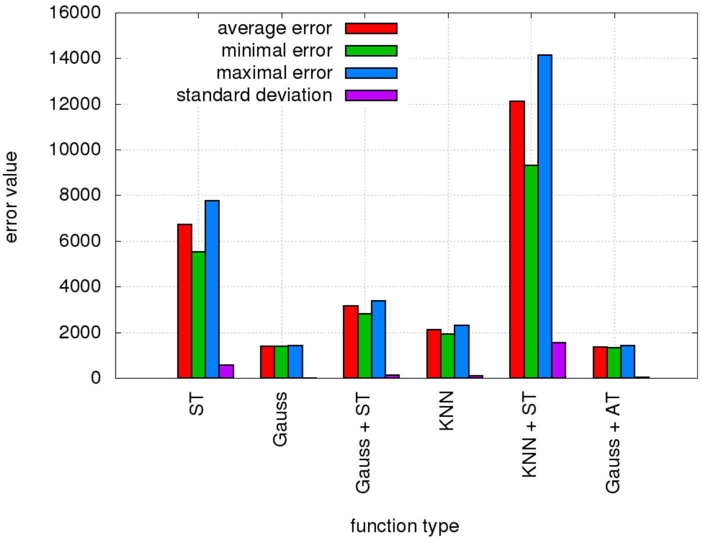

Mapa 3 - Výsledky experimentov

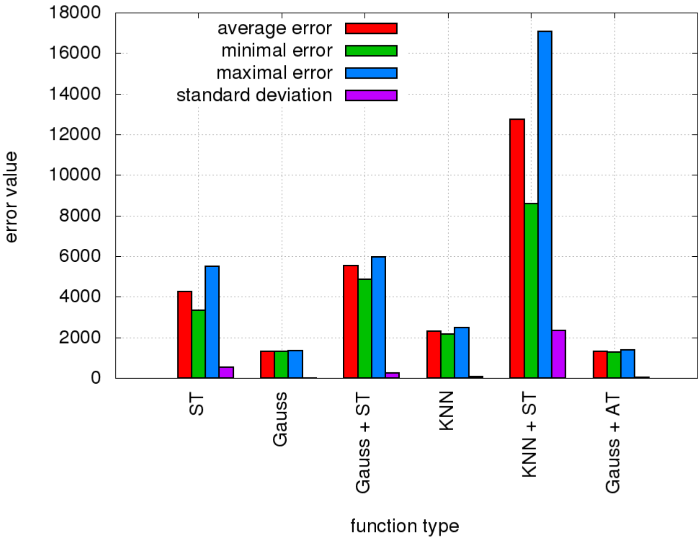

Ďakujem za pozornosť

michal.chovanec@yandex.ru

https://github.com/michalnand/q_learning