Q-learning - umelá inteligencia na obzore?

Ing. Michal CHOVANEC
Fakulta riadenia a informatiky

Apríl 2016

Obsah

- Reinforcement learing
- Q-learning algoritmus
- Možnosti aproximácie

Reinforcement learing

- Zistenie stavu
- Výber akcie
- Vykonanie akcie
- Prechod do ďalšieho stavu
- Získanie odmeny alebo trestu
- Učenie sa zo získanej skúsenosti

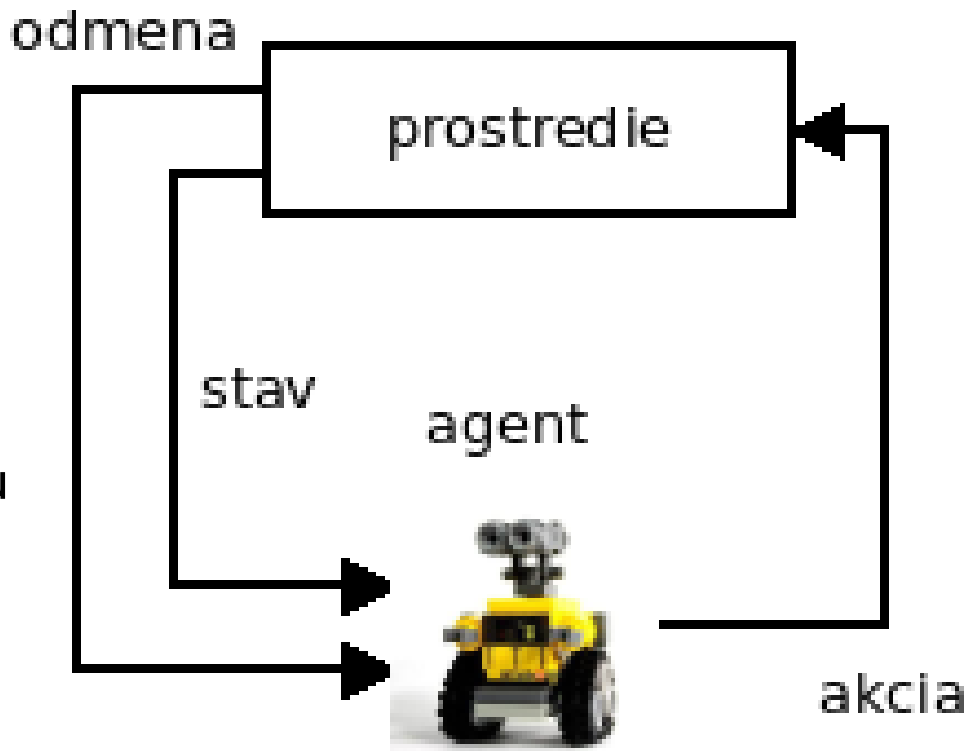

Výhody

Definuje sa čo robiť, nie ako to robiť

- vďaka odmeňovacej funkcií
- agent sa môže naučiť všetky detaily problému

Lepšie konečné riešenie

- založené na skutočnej skúsenosti, nie skúsenosti programátora
- treba menej ľudského času na nájdenie dobrého riešenia

Markovov rozhodovací proces

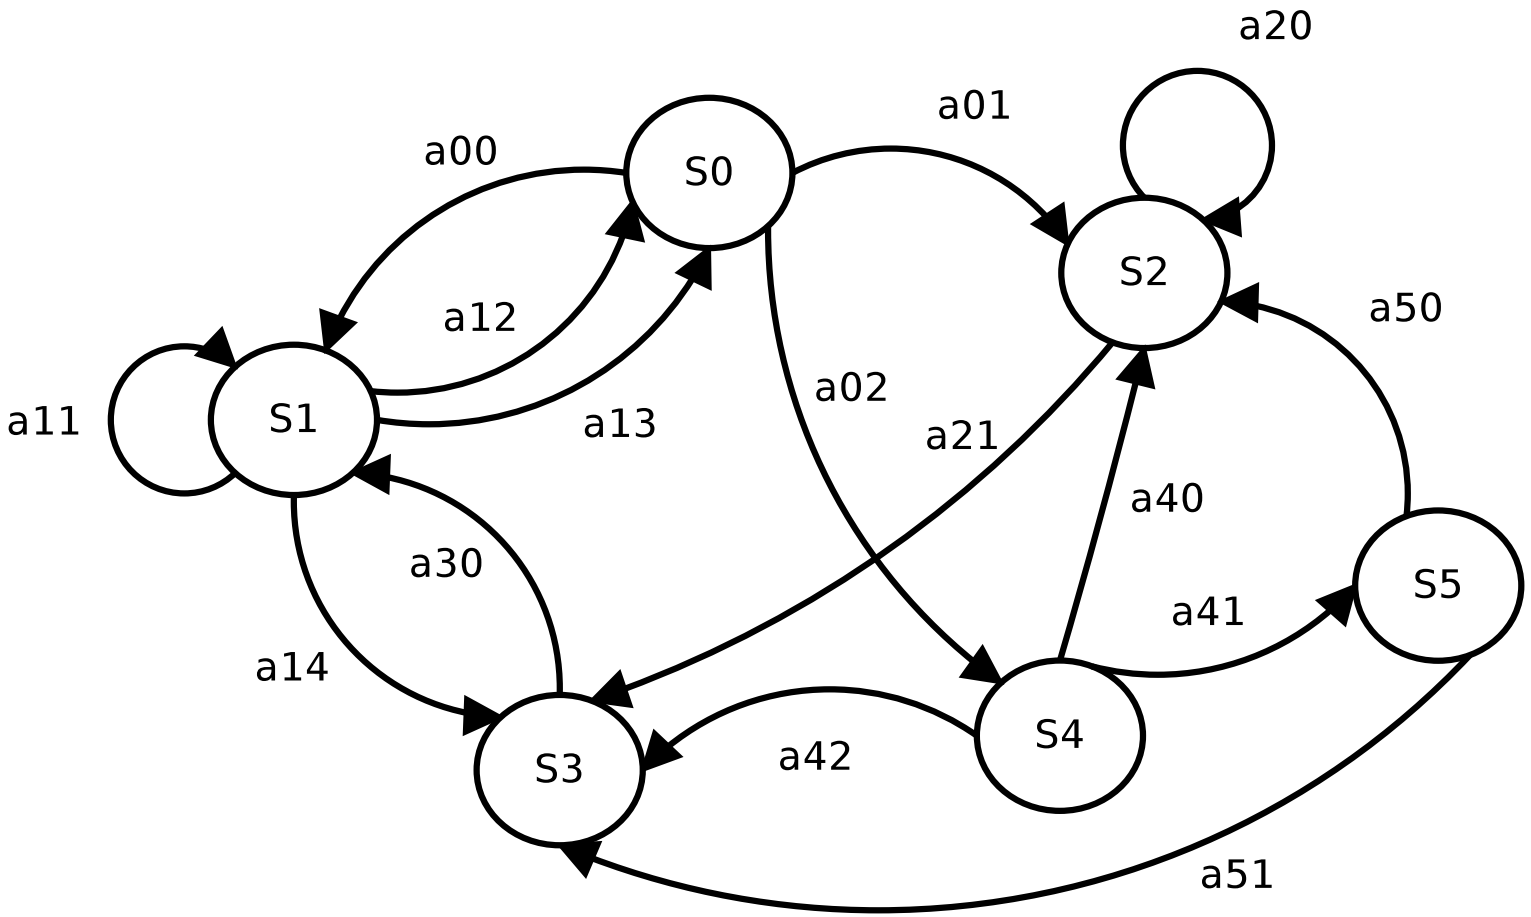

Experiment s jedným stavom - nanoQ learning

Plánovanie pohybu robota - aký krok má robot vybrať? Dostupné akcie : vľavo, vpravo, vpred, (vzad)

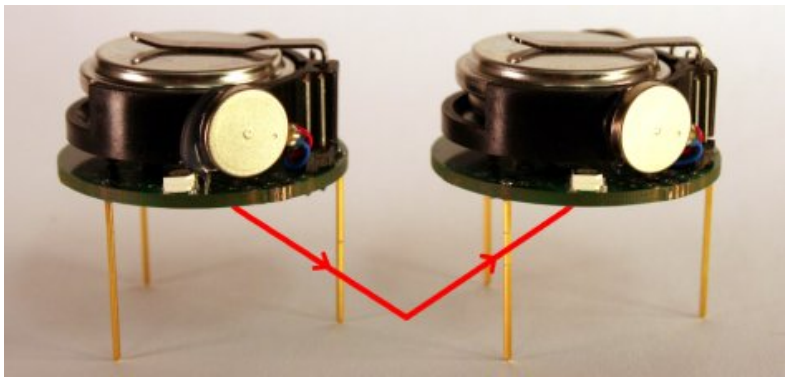

Robot s jednoduchým senzorom

- smer nie je známy
- známa je len vzdialenosť
- šum

Experiment s jedným stavom - nanoQ learning

- Najjednoduhší prípad Q-learning algoritmu
- Reward zadaný dvoma hodnotami :
  - situácia sa zlepšuje $+1$
  - situácia sa zhoršuje -1
- Voliteľná prevdepodobnosť $p \in \langle 0, 4 \rangle$ náhodnej zmeny rewardu - šum

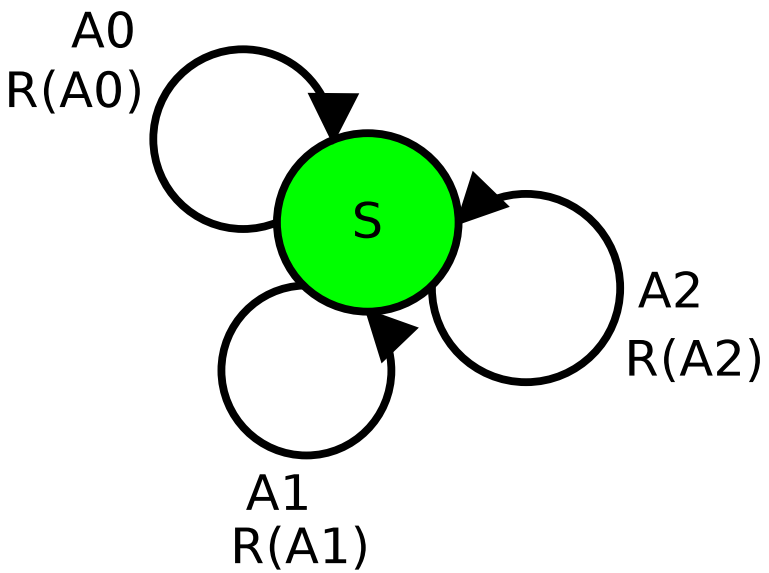

$$Q_n(A(n)) = R(n) + \gamma \max_{a'(n-1) \in \mathbb{A}} Q_{n-1}(a'(n-1)) \qquad (1)$$

Výber akcie

$$a(n) = \begin{cases} a(n-1) & ak\ Q_{n-1}(a(n-1)) > 0 \\ random() & inak \end{cases} \tag{2}$$

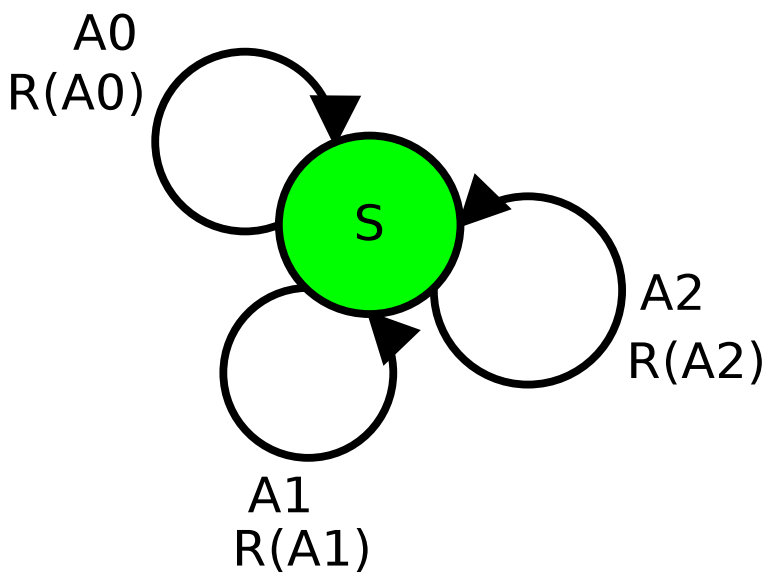

Výsledky

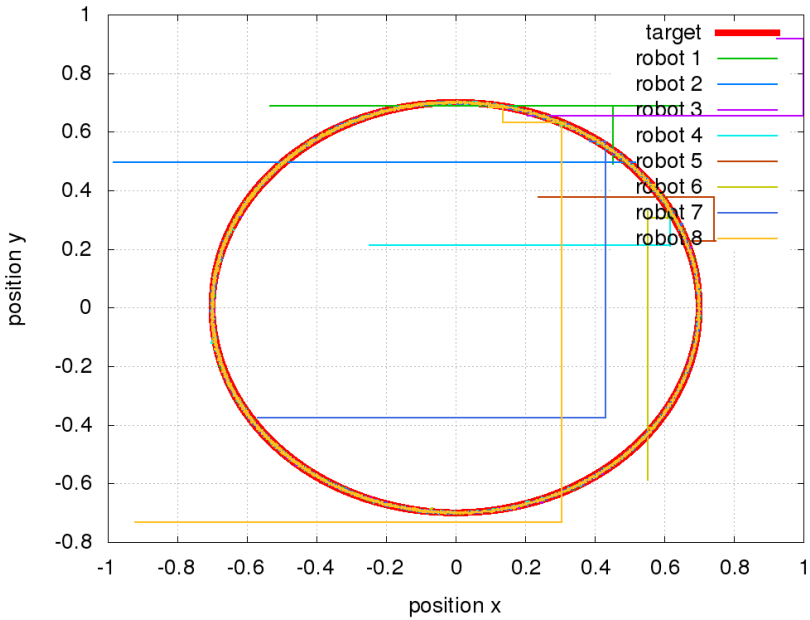

Obr.: Dráha robotov pre $\gamma = 0.7 p = 0.0$

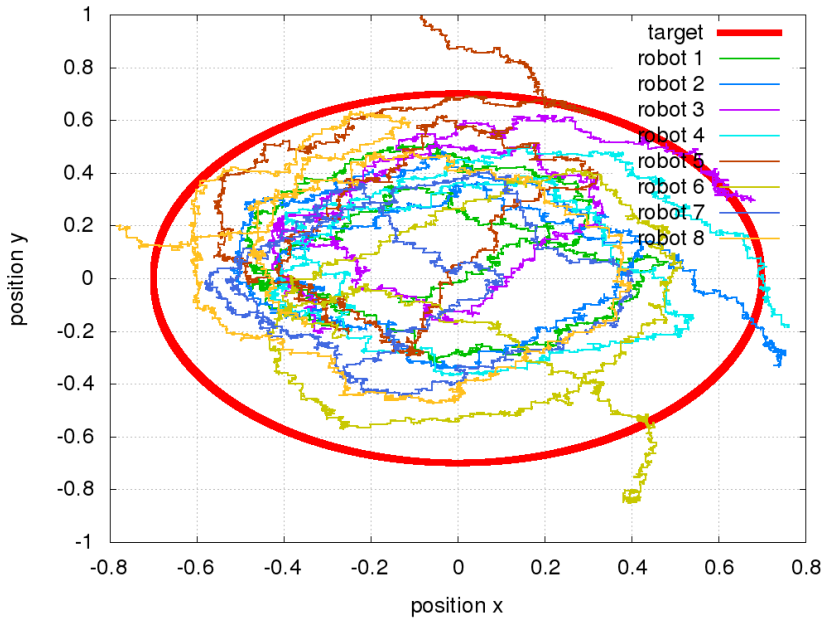

Obr.: Dráha robotov pre $\gamma = 0.7 p = 0.4$

Výsledky

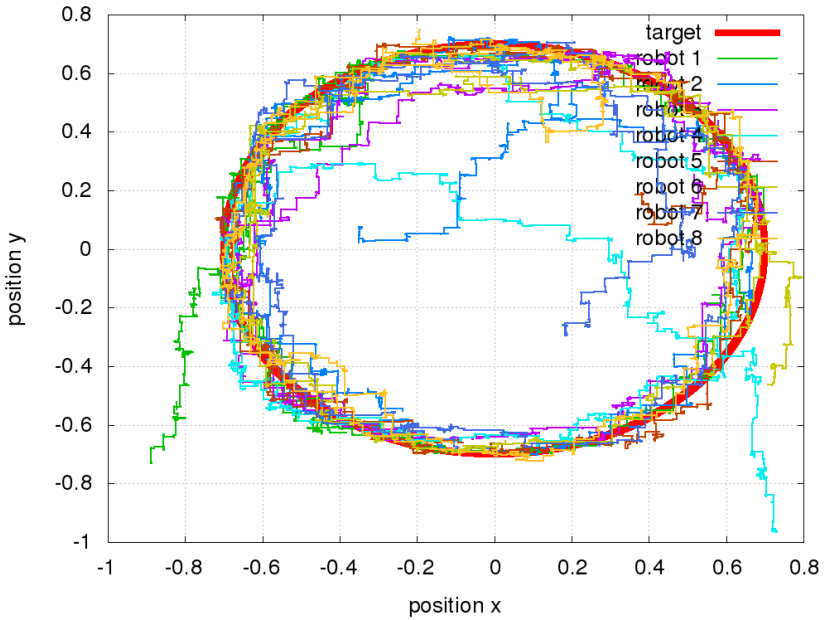

Obr.: Dráha robotov pre $\gamma = 0.9 p = 0.4$

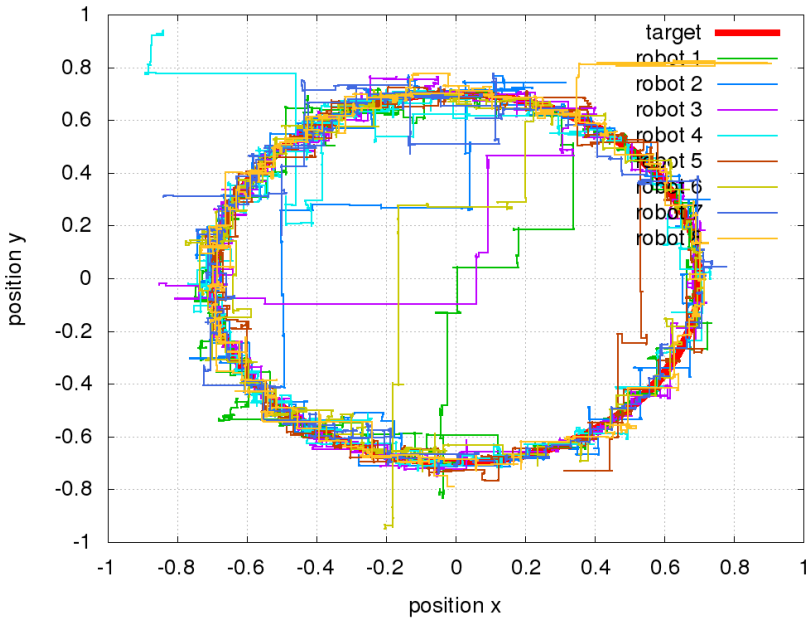

Obr.: Dráha robotov pre $\gamma = 0.98 p = 0.4$

Výsledky - zhrnutie

Komplexné vyšetrenie závislosti γ a p. Znázornenie funkcie vzdialenosti od pohyblivého cieľa po 25000 krokoch robota, priemer z 32 robotov

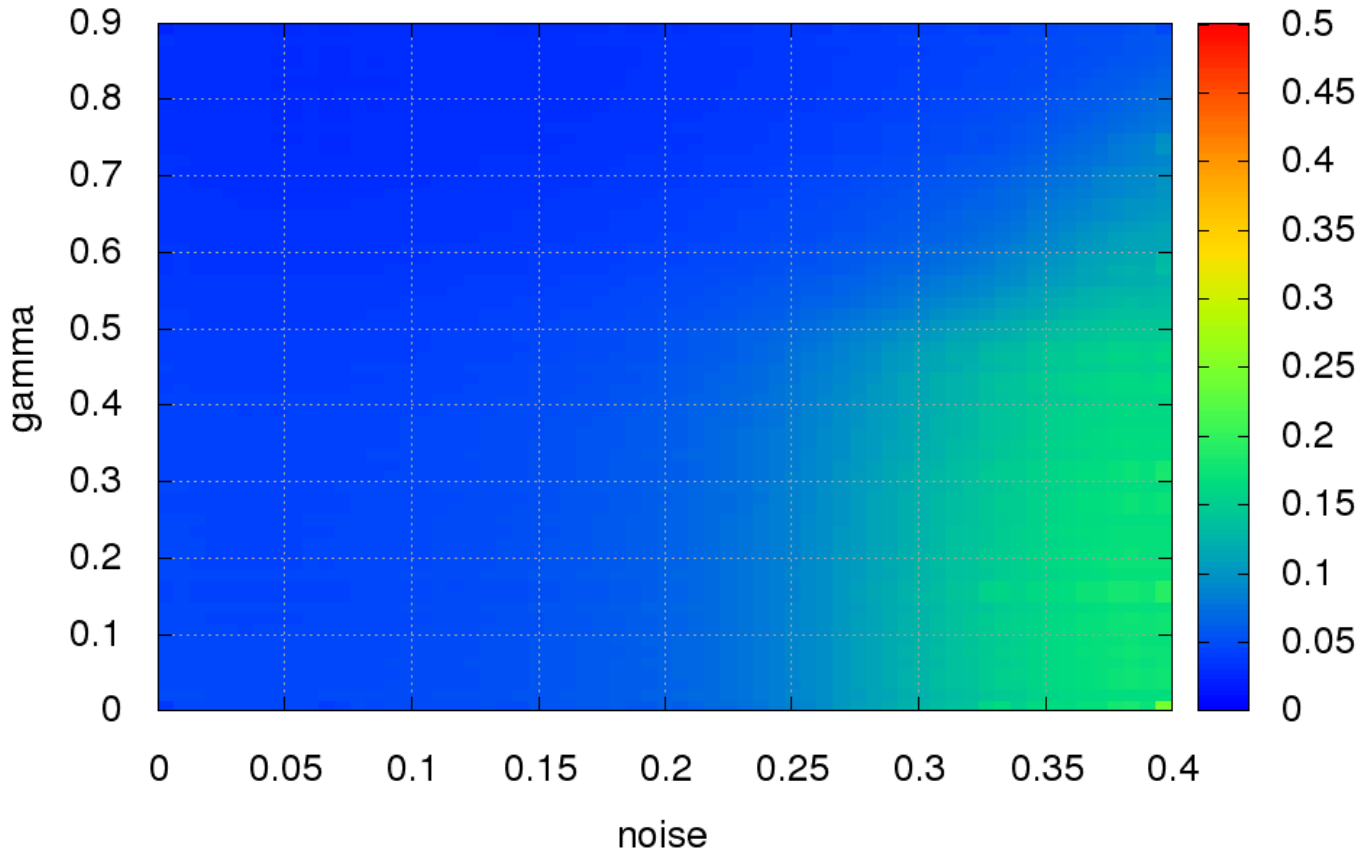

Q-learning algoritmus

Daná je funkcia ohodnotení

$$Q(s(n), a(n)) = R(s(n), a(n)) + \gamma \max_{a(n-1) \in \mathbb{A}} Q(s(n-1), a(n-1))$$

kde

- $R(s(n), a(n))$ je odmeňovacia funkcia s hodnotami v $\langle -1, 1 \rangle$,
- $Q(s(n-1), a(n-1))$ je odmeňovacia funkcia v stave $s(n-1)$ pre akciu $a(n-1)$,
- γ je odmeňovacia konštanta a platí $\gamma \in (0, 1)$.

Odmeňovacia funkcia

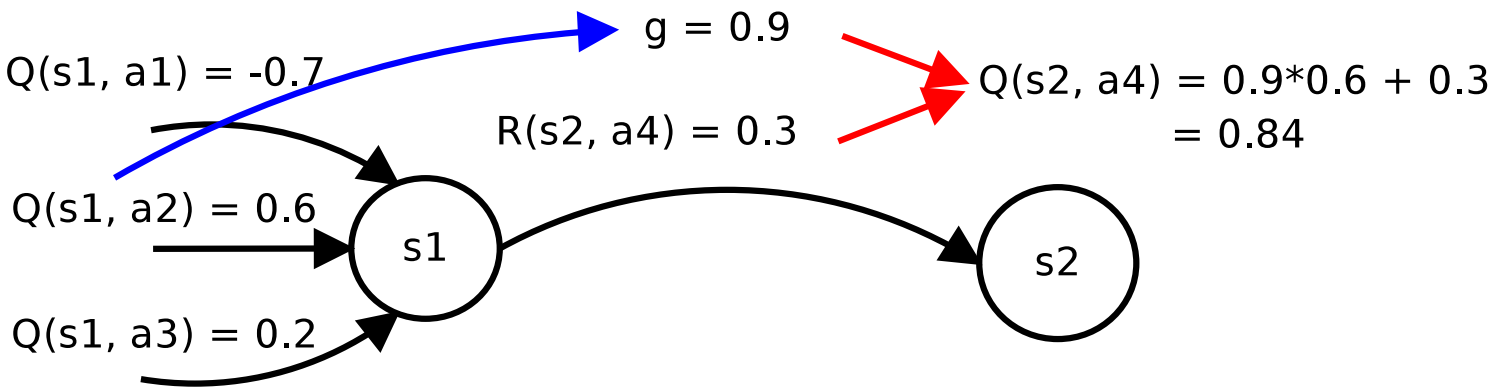

Rozsiahly stavový priestor - ukážka požadovaného tvaru funkcie

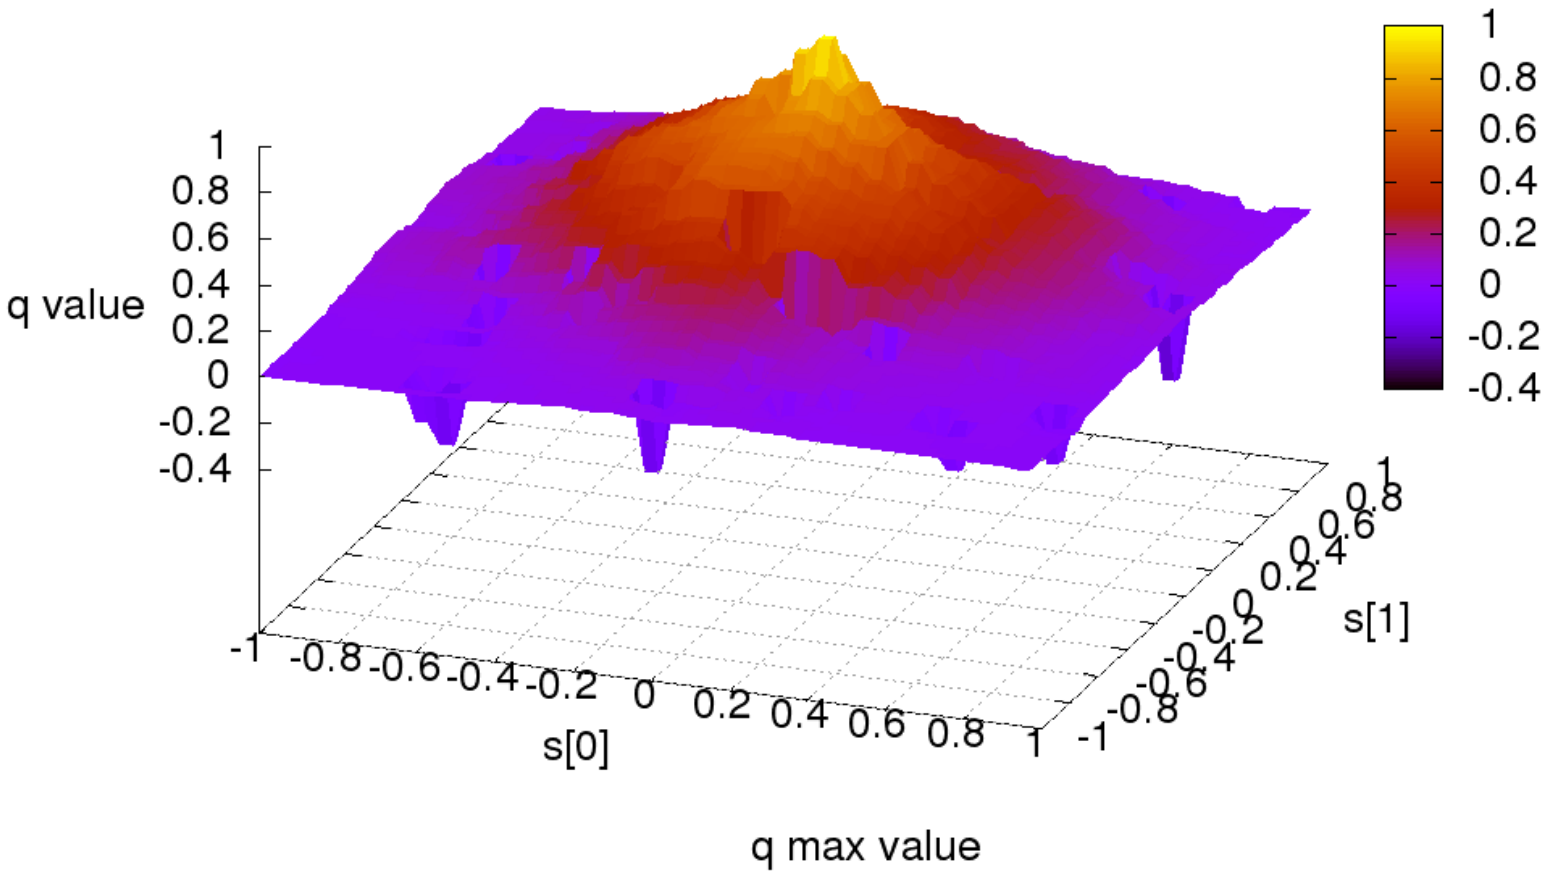

Implementačné problémy

Problémy tabuľkovej interpretácie $Q(s(n), a(n))$:

- pre veľké n_s alebo n_a narastajú pamäťové nároky,
- o nevyplnených $Q(s(n), a(n))$ nevieme povedať nič,
- pre rozsiahle stavové priestory ťažko vypočítateľné,
- ako aproximovať $Q(s(n), a(n))$?

Je možné zostaviť neurónovú sieť, ktorá sa dá naučiť lokálne?

Experiment s novou bázickou funkciou

Experimentálne sa zitili typické rysy funkcie pre

$$Q_n(s(n), a(n)) = R(s(n), a(n)) + \gamma \max_{a(n-1)\in\mathbb{A}} Q_{n-1}(s(n-1), a(n-1))$$

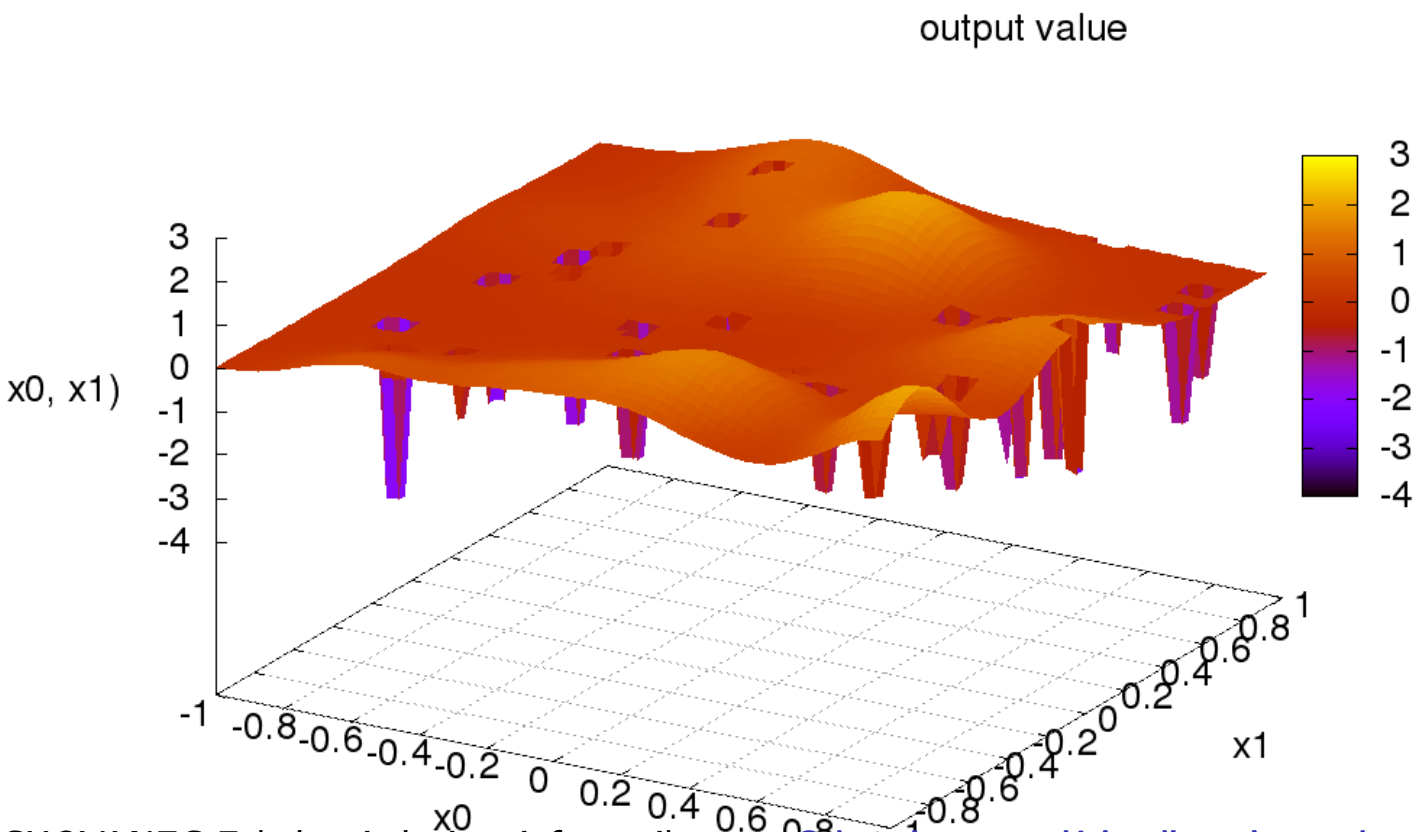

Experiment s novou bázickou funkciou

Peak and **H**ill funkcia

$$P_i(s(n), a(n)) = \begin{cases} r_{ai} & if\ s(n) = \alpha_i^1 \\ 0 & inak \end{cases} \tag{3}$$

$$H_j(s(n), a(n)) = w_{aj} e^{-\beta_{aj} \sum_{i=1}^{n_s} (s_i(n) - \alpha_{aji}^2)^2} \tag{4}$$

$$Q(s(n), a(n)) = \sum_{i=1}^{I} P_i(s(n), a(n)) + \sum_{j=1}^{J} H_j(s(n), a(n)) \tag{5}$$

kde
α_j^1 sú oblasti kde $H_j(s(n))$ nadobúda nenulové hodnoty
α_j^2 sú oblasti pre ktoré $f_j(s(n), a(n))$ nadobúda maximum
r_{ai} je hodnota okamžitej odmeny $R(s(n))$ v tomto stave
w_{aj} je váha a zobovedá veľkosti maxima resp. minima pre fukciu
β_{aj} je strmosť, a platí $\beta > 0$
I a J sú počty bázických funkcií

Schéma priebehu experimentov

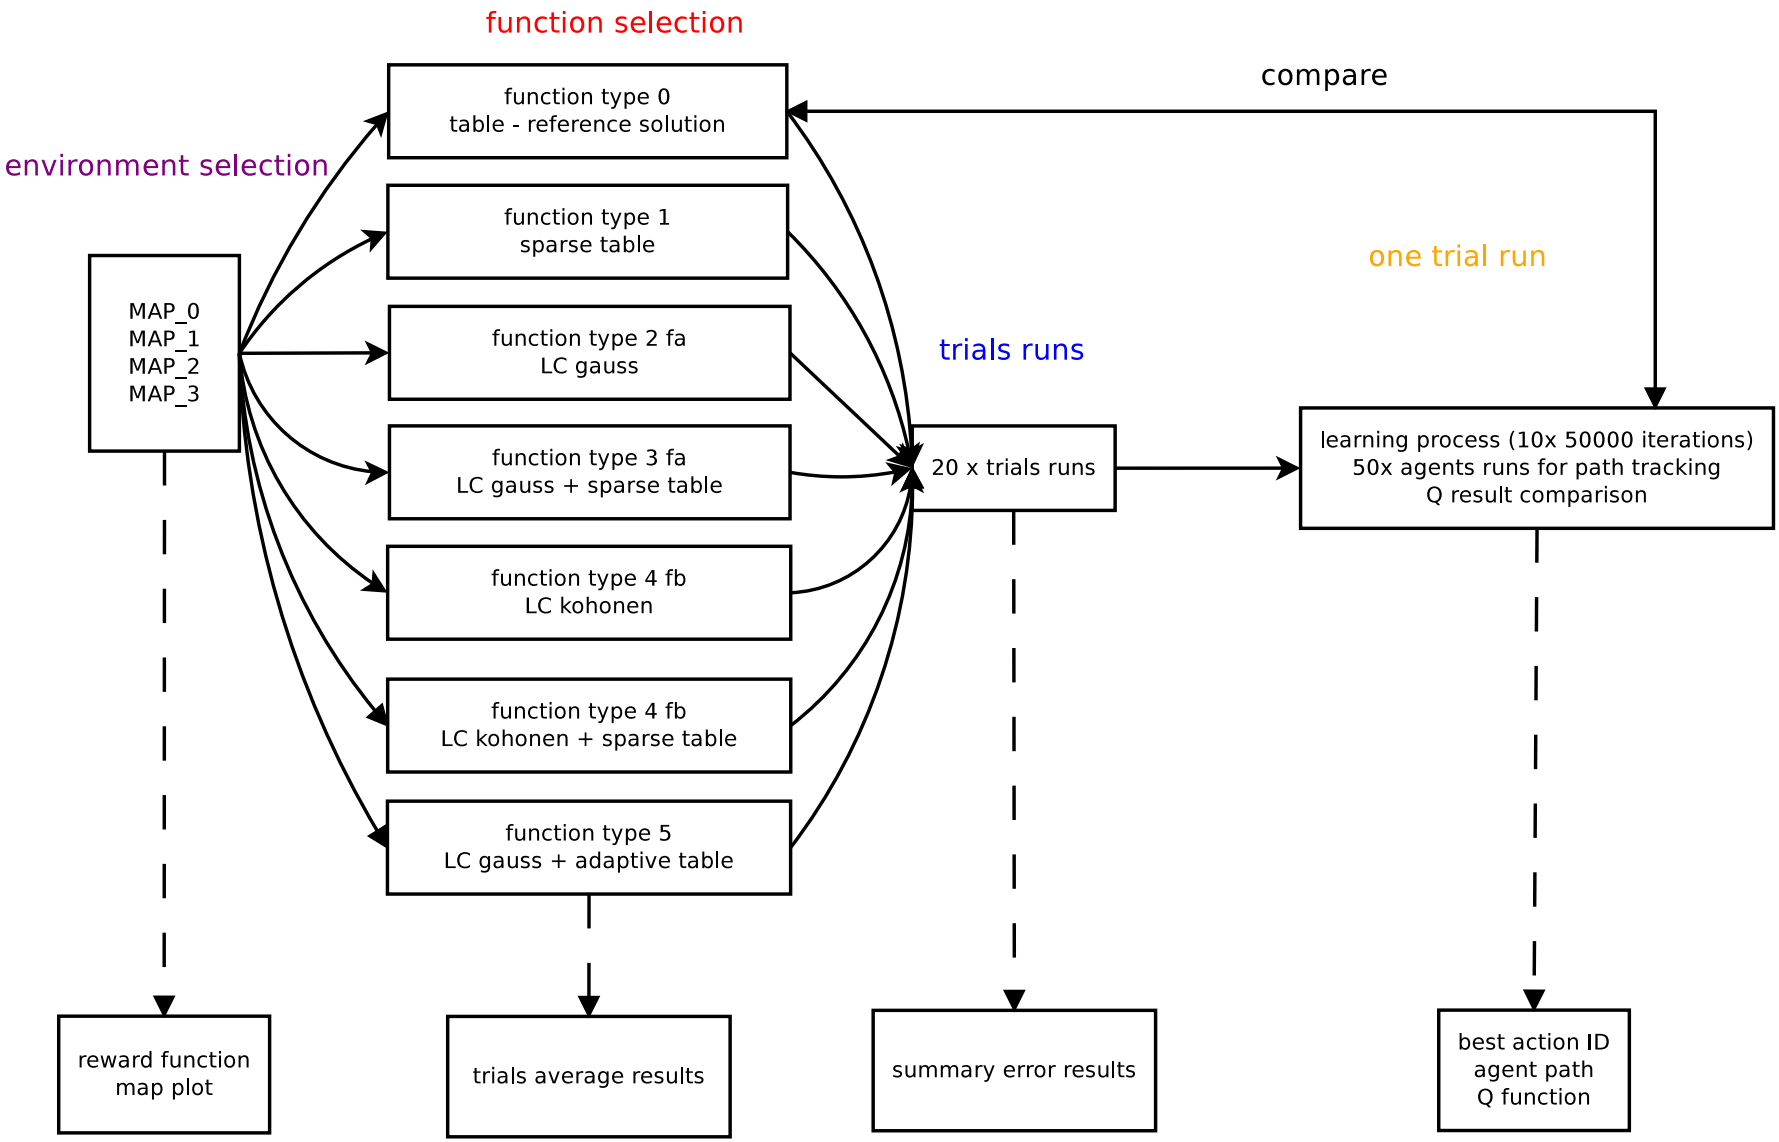

Porovnanie s ostatnými

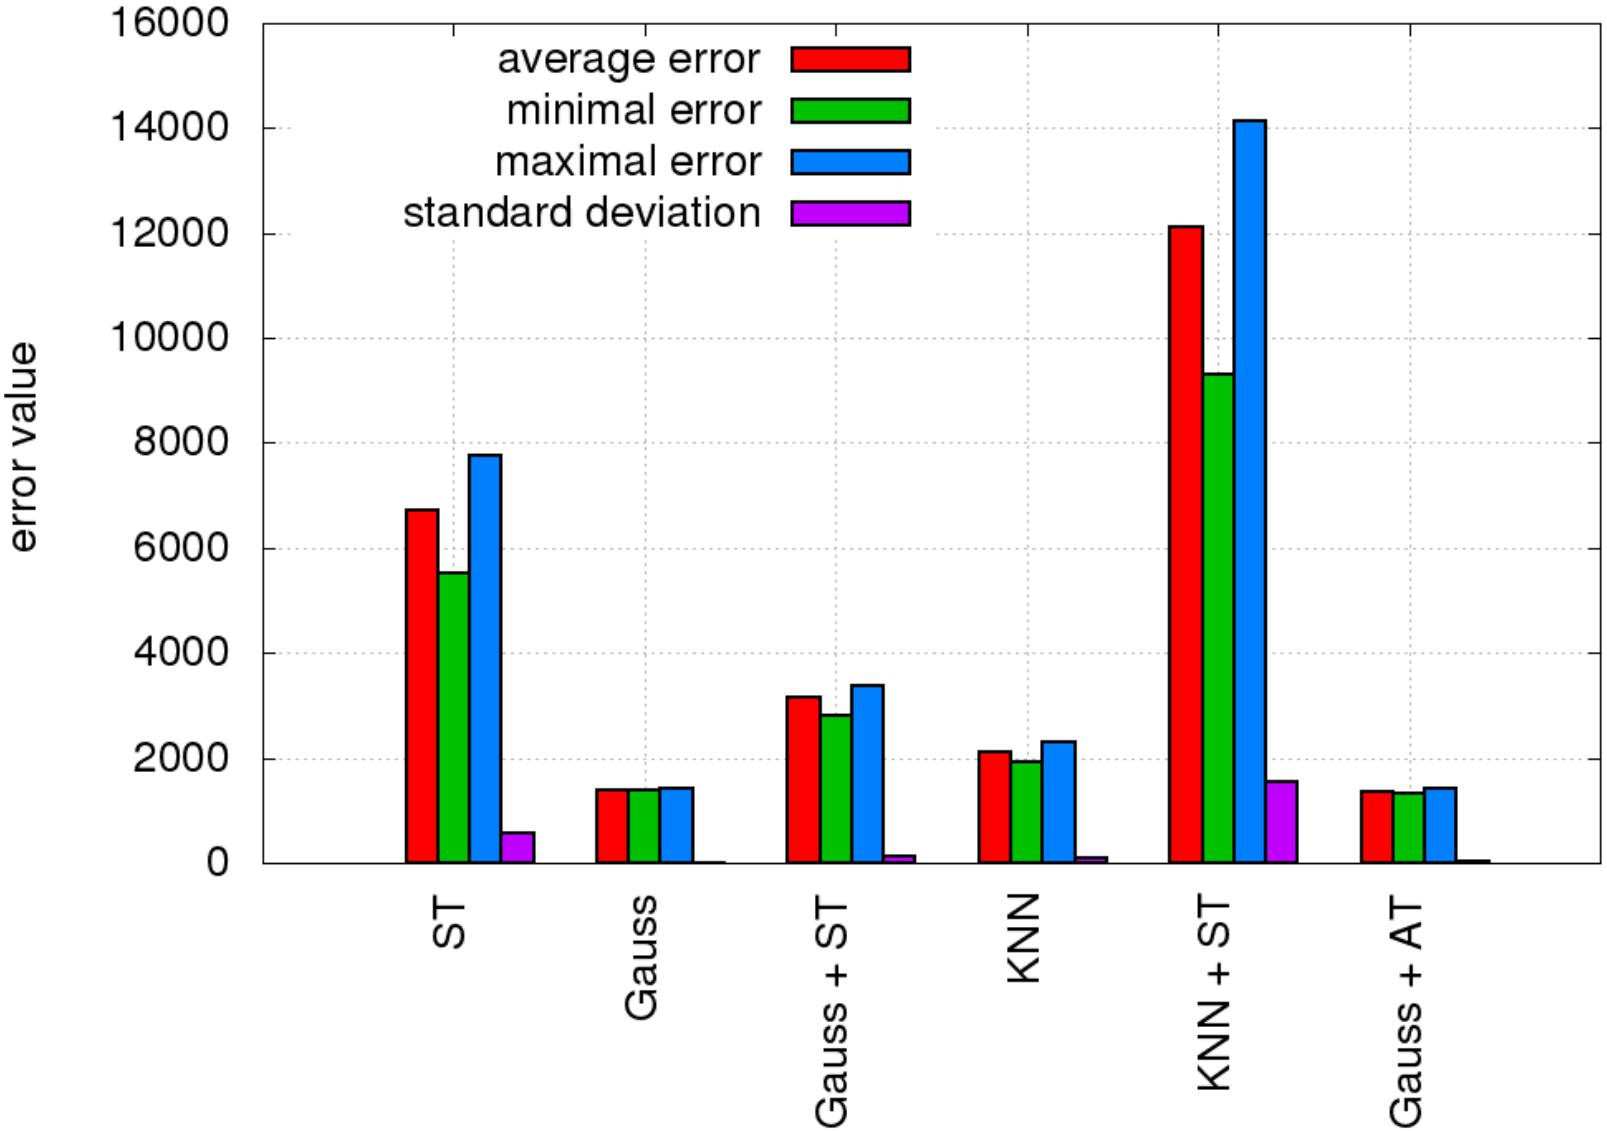

Porovnanie s ostatnými

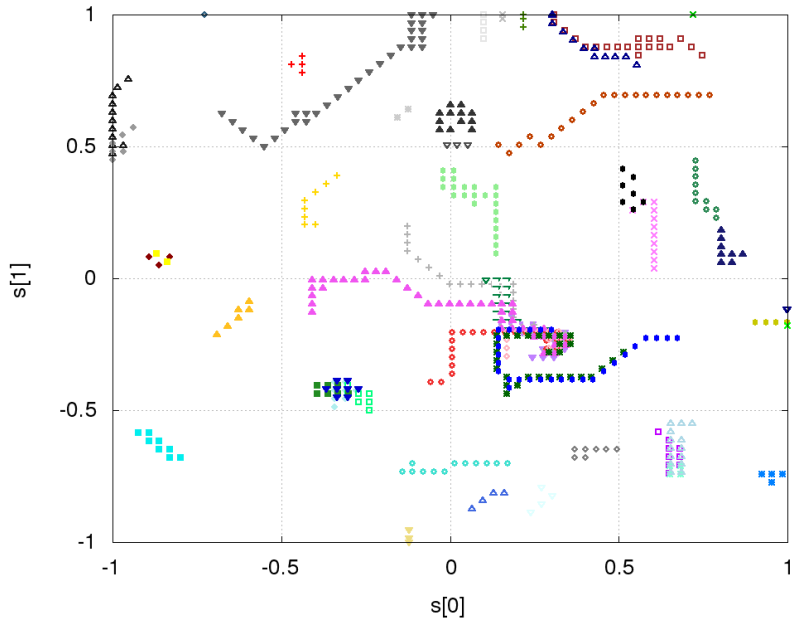

Obr.: Dráha robotov, funkcia 2 - Gauss

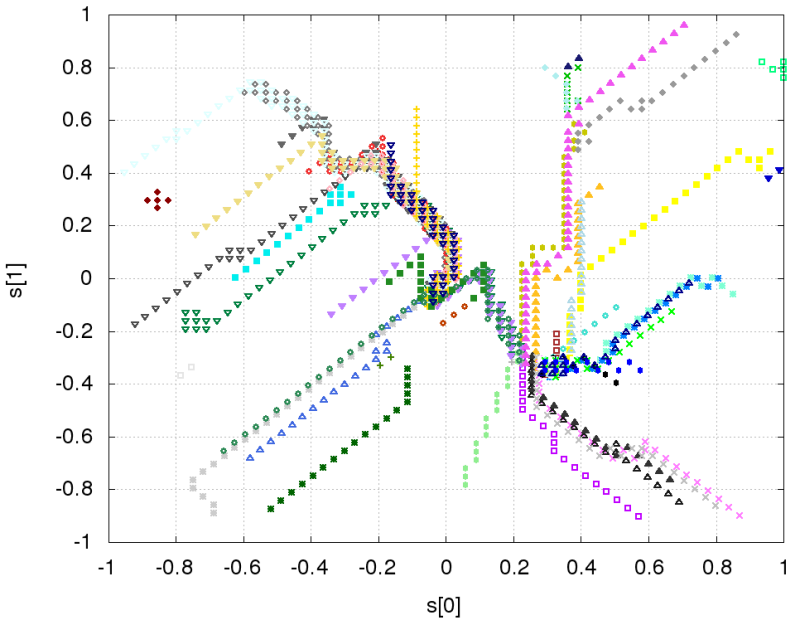

Obr.: Dráha robotov, funkcia 6 - Peak and Hill

Doplnkový experiment

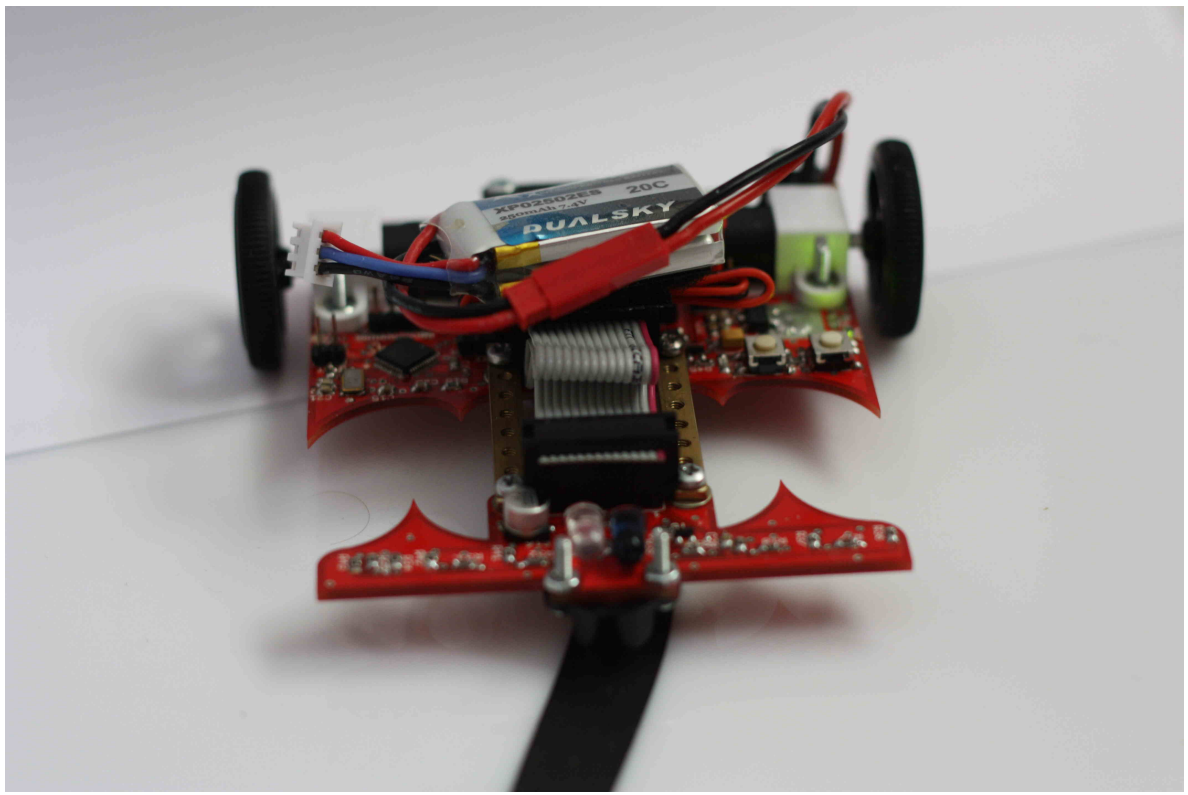

Doplnkový experiment

Bloková schéma robota

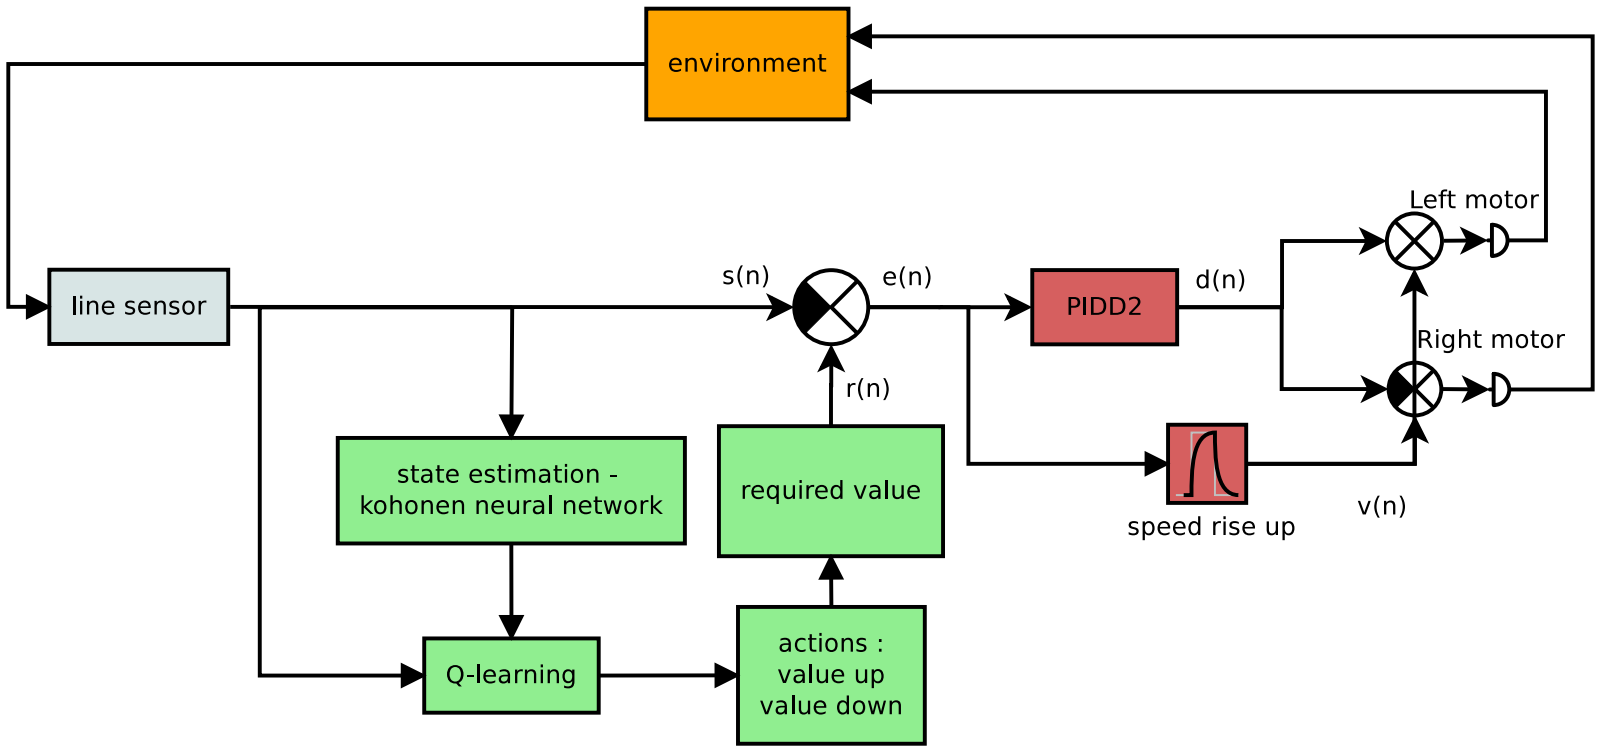

Ďakujem za pozornosť

michal.chovanec@yandex.ru
https://github.com/michalnand/q_learning