




Aproximácia funkcie ohodnotení v algoritmoch Q-learning

Michal CHOVANEC
Fakulta riadenia a informatiky

Marec 2016


- Úvod
 - Agentové systémy
 - Adaptívne a učiace sa systémy
- Q-learning algoritmus
- Možnosti aproximácie
- výsledky

Agentové systémy



Racionálny agent :


- Schopný vnímať prostredie
- Robiť rozhodnutia
- Pre každú možnú postupnosť vstupov vyberá akciu maximalizujúcu očakavaný výkon






Obr. : Multiagentný systém

Adaptívne a učiace sa systémy

Adaptívny systém




Učiaci sa systém



Adaptívne a učiace sa systémy


Adaptívny systém PID regulátor

$$C(z) = \frac{b_0 + b_1 z^{-1} + b_2 z^{-2}}{1 - z^{-1}}$$



Učiaci sa systém Iterative learning controll

$$C(w) = \frac{\gamma}{1 - w^{-1}}$$



Q-learning algoritmus

Daná je monožina stavov a akcií

$$s \in \mathbb{S}$$

$$a \in \mathbb{A}$$

kde $\mathbb{S} \in \mathbb{R}^{N_s}$ a $\mathbb{A} \in \mathbb{R}^{N_a}$.

Predpoklad : v prostredí existuje funkcia

$$s(n+1) = \lambda(s(n), a(n)) \quad (1)$$

prechodová funkcia zo stavu $s(n)$ použitím akcie $a(n)$ - táto funkcia je ale agentovi neznáma.

Cieľom je nájsť takú postupnosť akcií $a \in \mathbb{A}$ pre ktorú bude maximálne

$$y = \prod_{i=1} Q_i(s_i, a_i) \quad (2)$$

Daná je funkcia ohodnotení

$$Q(s, a) = R(s, a) + \gamma \max_{a' \in \mathbb{A}} Q'(s', a') \quad (3)$$

kde


$R(s, a)$ je odmeňovacia funkcia,

$Q'(s', a')$ je odmeňovacia funkcia z ktorej sa agent dostal zo stavu " s' " vykonaním " a " do stavu " s ",


γ je odmeňovacia konštanta a platí $\gamma \in (0, 1)$.

Q-learning algoritmus


TODO




Q-learning algoritmus




Q-learning algoritmus




Q-learning algoritmus



Q-learning algoritmus



Q-learning algoritmus




Problémy tabuľkovej interpretácie $Q(s, a)$

- pre veľké N_s *alebo* N_a narastajú pamäťové nároky
- o nevyplnených $Q(s, a)$ vieme povedať nič
- pre rozsiahle stavové priestory nevypočítateľné
- ako aproximovať $Q(s, a)$?


Q-learning algoritmus - aproximácia

Neurónová sieť? Utopická predstava :



prečo nedáva správne výsledky?

Q-learning algoritmus - aproximácia



Pre korektné vyplnenie hodnôt v s_{n-1} sa vyžaduje korektá hodnota v s_n

$$Q(s_0, a_0) = R(s_0, a_0) + \gamma \max_{a'_1 \in \mathbb{A}} Q'(s_1, a'_1)$$

$$Q(s_1, a_1) = R(s_1, a_1) + \gamma \max_{a'_2 \in \mathbb{A}} Q'(s_2, a'_2)$$

$$Q(s_2, a_2) = R(s_2, a_2) + \gamma \max_{a'_3 \in \mathbb{A}} Q'(s_3, a'_3)$$

...

(4)


Q-learning algoritmus - aproximácia

Učenie doprednej siete nie je homogénne!

- v priebehu učenia $Q(s, a)$ chaoticky osciluje okolo požadovanej hodnoty
- ani po 10-tkach milónoch iterácií sa hodnota neustáli na požadovanej hodnote

Q-learning algoritmus - aproximácia

Je možné zostaviť neurónovú sieť ktorá sa dá učiť lokálne?



Q-learning algoritmus - aproximácia

Rozklad na bázické funkcie

$$f_j(X) = e^{\sum_{i=1}^{N_s} -b_{ji}(x_i - a_{ji})^2} \quad (5)$$

pre symetrické prechody medzi stavmi možno zjednodušiť na

$$f_j(X) = e^{-b_j \sum_{i=1}^{N_s} (x_i - a_{ji})^2} \quad (6)$$

A ich kombinácia

$$\begin{aligned} y(X) = & \sum_{j=1}^N w_j f_j(X) \\ & + \sum_{j=1}^N \sum_{i=1}^j v_{ji} f_j(X) f_i(X) \end{aligned} \quad (7)$$

Stavenie parametrov :

- bázicke funkcie musia rovnomerne pokryť stavový priestor
- parameter a_j reprezentuje posunutie Gaussovej krivky - bod s najväčšou funkčnou hodnotou.
- parameter b_j reprezentuje strmosť krivky

Q-learning algoritmus - aproximácia

Parametre a_{ji} - pokrytie stavového priestoru do oblastí podľa veľkosti $R(s, a)$ Využije sa princíp Kohenovej siete - najbližšie vzory a_j sa posunú podľa vstupných vektorov tak aby vrchol Gaussovej krivky ležal v ťazisku.

- na začiatku sa zvolia a_{ji} náhodne
- spočítajú sa vzdialenosti od predloženého vstupu $d_j = |X - a_j|$
- nájde sa také k kde $\forall j : d_k \leq d_j$
- spočíta sa krok učenia $\eta' = \eta_1 | y_r |$
- upravia sa parametre $a_{ki} = (1 - \eta')a_{ki} + \eta'x_i$

kde

X je vstupný vektor

y_r je požadovaný výstup

η_1 je krok učenia

Q-learning algoritmus - aproximácia

Parametre b_j - určuje strmosť krivky

- stanoví sa chyba $e(n) = y_r(n) - y(n)$
- pre každú bázičku funkciu $b_j(n+1) = b_j(n) - \eta_2 e(n) w_j(n)$
- skontroluje sa $b_j \in (0, -\infty)$

kde

y_r je požadovaný výstup

y je výstup

η_2 je krok učenia

Q-learning algoritmus - aproximácia

Parametre w_j - váhové parametre

- stanoví sa chyba $e(n) = y_r(n) - y(n)$
- pre každé w_j : $w_j(n+1) = w_j(n) - \eta_3 e(n) b_j(n)$
- skontroluje sa $w_j \in (-a, a)$

kde

η_3 je krok učenia

a je maximálny rozsah váh

Ďakujem za pozornosť

michal.chovanec@yandex.ru